Estudio Analítico de AB Testing

November 11, 2026

1 Estudio Analítico de A/B Testing: Optimización de Tasa de Conversión y Ticket Promedio en E-Commerce

Autora: Alison Ixchel Maertens Gaona
Enfoque: Análisis Estadístico Inferencial & Evaluación de Cohortes

El objetivo de este estudio es analizar el comportamiento de los usuarios expuestos a dos versiones de la página de inicio (A: Control vs. B: Variante) a partir del dataset landing_experiment.csv.

Estructura del Análisis: - **Validación de Integridad y SRM:** Verificación de aleatorización, datos nulos y consistencia de datos. - **Evaluación de Gasto (AOV):** Comparación paramétrica/no paramétrica del gasto promedio por usuario. - **Tasa de Conversión (CR):** Análisis de proporciones entre versiones A y B. - **Análisis Cohortes y Tráfico:** Evaluación de interacción entre tipo de usuario, canal de origen y rendimiento del experimento.

1.1 Carga y Validación de Datos

[1]:
```
# importar librerías
import pandas as pd
from scipy.stats import levene, ttest_ind
from statsmodels.stats.proportion import proportions_ztest
from scipy.stats import chi2_contingency
import matplotlib.pyplot as plt
import seaborn as sns

import numpy as np
from scipy import stats
import statsmodels.api as sm
import statsmodels.formula.api as smf

# Configuración de estilo visual para informe ejecutivo
sns.set_theme(style="whitegrid")
plt.rcParams["figure.figsize"] = (10, 5)
```

[2]:
```
# cargar archivo
df = pd.read_csv('/datasets/landing_experiment.csv')
```

Vista previa e información general del conjunto de datos

[3]:
```
# mostrar las primeras 5 filas
df.head()
```

[3]:

	user_id	date	landing	region	\
0	26f3052e-8500-44ea-8fff-06de65258abb	2026-01-01	A	Norte	
1	92378c09-4bbf-40c7-945e-82b84f392d22	2026-01-23	A	Occidente	
2	a4397360-40e5-45d6-a7ff-dcb4da2c9a1f	2026-01-01	B	Centro	
3	7ca3a26f-1e6c-44aa-9b09-b8cb01112956	2026-01-22	A	Centro	
4	8dc9593b-5b9c-479d-848b-a99493920419	2026-01-16	A	Sur	

	dispositivo	traffic_source	user_type	converted	gasto
0	Mobile	Email	Recurrente	1	38.08
1	Mobile	Organic	Nuevo	0	0.00
2	Mobile	Organic	Nuevo	0	0.00
3	Mobile	Ads	Nuevo	0	0.00
4	Mobile	Organic	Nuevo	0	0.00

[4]:
```
# información general
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 40000 entries, 0 to 39999
Data columns (total 9 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   user_id         40000 non-null  object
 1   date            40000 non-null  object
 2   landing         40000 non-null  object
 3   region          40000 non-null  object
 4   dispositivo     40000 non-null  object
 5   traffic_source  40000 non-null  object
 6   user_type       40000 non-null  object
 7   converted       40000 non-null  int64
 8   gasto           40000 non-null  float64
dtypes: float64(1), int64(1), object(7)
memory usage: 2.7+ MB
```

Hallazgos sobre la Estructura de Datos: El dataset cuenta con 40,000 registros y 0 valores nulos. Se identifican las siguientes acciones de preparación: - **Columna `date`:** Se transformará de texto (`object`) a formato `datetime` para permitir análisis de tendencias y coherencia temporal. - **Columna `converted`:** Registrada en formato binario (0/1). Adecuada para cálculo de tasas e inferencia estadística.

Descripción del conjunto de datos

El dataset contiene las siguientes columnas:

- `user_id` — Identificador único del usuario
- `date` — Fecha en la que el usuario fue expuesto a la página

- `landing` — Versión de la página mostrada al usuario
- `region` — Región geográfica del usuario
- `dispositivo` — Tipo de dispositivo utilizado por el usuario
- `traffic_source` — Canal por el que llegó el usuario
- `user_type` — Tipo de usuario según historial previo
- `converted` — Indica si el usuario realizó una conversión
- `gasto` — Monto gastado por el usuario (0 si no convirtió)

1.1.1 Exploración Multivariada y Control de Calidad de Datos

Se valida la integridad del conjunto de datos mediante la verificación de usuarios únicos, la amplitud del período de prueba y el balance en la asignación de variantes (Experimento A/B).

Variable `user_id`
Verificar usuarios únicos

[5]:
```
df['user_id'].describe()
```

[5]:
```
count                                    40000
unique                                   40000
top       1a790cd6-62fb-43ae-aabc-e1a7772c4aa8
freq                                         1
Name: user_id, dtype: object
```

Variable `date`
Explorar rango de fechas

[6]:
```
# Conversión de tipos de datos y control de unicidad
df['date'] = pd.to_datetime(df['date'])

print(f"Total de registros: {len(df):,}")
print(f"Usuarios únicos: {df['user_id'].nunique():,}")
print(f"Rango temporal del experimento: {df['date'].min().strftime('%Y-%m-%d')}␣
 ↪al {df['date'].max().strftime('%Y-%m-%d')}")
```

```
Total de registros: 40,000
Usuarios únicos: 40,000
Rango temporal del experimento: 2026-01-01 al 2026-01-28
```

[7]:
```
# Identificar rango temporal del experimento
print("Fecha mínima:", df["date"].min())
print("Fecha máxima:", df["date"].max())
```

```
Fecha mínima: 2026-01-01 00:00:00
Fecha máxima: 2026-01-28 00:00:00
```

Variable `gasto` (numérica)

[8]:
```
# Resumen estadístico del gasto general vs. usuarios convertidos
gasto_general = df['gasto'].describe()
```

```
gasto_convertidos = df[df['converted'] == 1]['gasto'].describe()

pd.DataFrame({'Gasto Total': gasto_general, 'Gasto (Solo Convertidos)':␣
 ↪gasto_convertidos})
```

[8]:

	Gasto Total	Gasto (Solo Convertidos)
count	40000.000000	5706.000000
mean	9.325554	65.373668
std	25.667986	30.896545
min	0.000000	12.120000
25%	0.000000	42.950000
50%	0.000000	59.860000
75%	0.000000	80.370000
max	303.680000	303.680000

Variables categóricas

Verificar categorías esperadas del experimento (A y B).

[9]:
```
# Evaluación del balance de la prueba (Sample Ratio Mismatch check)
print("=== Asignación del Experimento (Landing Page) ===")
print(df['landing'].value_counts())
print(df['landing'].value_counts(normalize=True).map('{:.2%}'.format))

# Distribución de variables categóricas
columnas_categoricas = ['traffic_source', 'user_type', 'region', 'dispositivo']

for col in columnas_categoricas:
    print(f"\n--- Distribución por: {col} ---")
    print(df[col].value_counts(dropna=False))
    print(df[col].value_counts(normalize=True).map('{:.2%}'.format))
```

```
=== Asignación del Experimento (Landing Page) ===
B    20018
A    19982
Name: landing, dtype: int64
B    50.04%
A    49.95%
Name: landing, dtype: object

--- Distribución por: traffic_source ---
Organic     17987
Ads         11935
Email        6123
Referral     3955
Name: traffic_source, dtype: int64
Organic     44.97%
Ads         29.84%
Email       15.31%
```

```
Referral     9.89%
Name: traffic_source, dtype: object

--- Distribución por: user_type ---
Nuevo         26033
Recurrente    13967
Name: user_type, dtype: int64
Nuevo         65.08%
Recurrente    34.92%
Name: user_type, dtype: object

--- Distribución por: region ---
Norte        11166
Centro        9613
Sur           8039
Occidente     6398
Oriente       4784
Name: region, dtype: int64
Norte        27.91%
Centro       24.03%
Sur          20.10%
Occidente    16.00%
Oriente      11.96%
Name: region, dtype: object

--- Distribución por: dispositivo ---
Mobile     24829
Desktop    15171
Name: dispositivo, dtype: int64
Mobile     62.07%
Desktop    37.93%
Name: dispositivo, dtype: object
```

[10]:
```python
# Verificación formal de SRM (Sample Ratio Mismatch)
from scipy.stats import chisquare
conteos = df['landing'].value_counts().sort_index()
chi2_srm, p_srm = chisquare(conteos)
print(f"Chi2 SRM: {chi2_srm:.4f} | Valor P: {p_srm:.4f}")
```

```
Chi2 SRM: 0.0324 | Valor P: 0.8572
```

Diagnóstico de Calidad y Validez del Experimento

- **Unicidad e Integridad:** Se confirmó una muestra exacta de 40,000 usuarios únicos (`user_id`), descartando registros duplicados o usuarios expuestos a múltiples variantes.
- **Periodo Operativo:** El experimento se mantuvo activo durante 28 días consecutivos (del 1 al 28 de enero de 2026).
- **Verificación de SRM (Sample Ratio Mismatch):** La distribución entre la versión Con-

trol (A) y Variante (B) está perfectamente balanceada al 50/50, garantizando la validez estadística para inferencia.

- **Segmentación de Tráfico y Dispositivos:**
  - **Tráfico:** Alta concentración en tráfico Orgánico (44.97%) y Ads/Paid (29.84%).
  - **Usuarios:** Prevalencia de usuarios Nuevos (65.08%) sobre Recurrentes (34.92%).
  - **Geografía:** La representación geográfica abarca 5 regiones principales, concentrando la mayor cuota en el Norte (27.92%) y Centro (24.03%), seguidos del Sur (20.10%), Occidente (16.00%) y Oriente (11.97%).
  - **Dispositivo:** Uso mayoritario de dispositivos Móviles (62.07%), lo que convierte al diseño *Responsive/Mobile-First* en un factor crítico de conversión.
- **Estructura del Gasto:** La variable `gasto` presenta una alta asimetría positiva debido a la densidad de ceros (85%+ no convertidos). El análisis de Ticket Promedio (AOV) debe realizarse filtrando estrictamente la cohorte con `converted == 1`.

1.2 Comparación del Ticket Promedio (AOV) por Versión de Página

Se evalúa si existen diferencias estadísticamente significativas en el gasto promedio de los **usuarios convertidos** entre la versión Control (A) y la Variante (B), con el fin de determinar qué diseño genera mayor valor económico.

[11]:
```
# Extracción del gasto de usuarios convertidos por variante
gasto_A = df[(df['converted'] == 1) & (df['landing'] == 'A')]['gasto']
gasto_B = df[(df['converted'] == 1) & (df['landing'] == 'B')]['gasto']

print(f"Muestra de usuarios convertidos - Versión A: {len(gasto_A):,} | Versión␣
 ↪B: {len(gasto_B):,}")
```

```
Muestra de usuarios convertidos - Versión A: 2,512 | Versión B: 3,194
```

1.2.1 Inferencia Estadística: Prueba de Hipótesis para Medias

Planteamiento de Hipótesis: * **Hipótesis Nula (H_0):** No existe diferencia significativa en el gasto promedio entre la versión A y B. * **Hipótesis Alternativa (H_1):** Existe una diferencia estadísticamente significativa en el gasto promedio entre la versión A y B.

[12]:
```
# Prueba de Levene para evaluar la homogeneidad de varianzas
levene_stat, levene_p = levene(gasto_A, gasto_B)

print("--- PRUEBA DE HOMOGENEIDAD DE VARIANZAS (LEVENE) ---")
print(f"Estadístico de Levene: {levene_stat:.4f}")
print(f"Valor P (Levene): {levene_p:.4e}")

# Determinar de forma dinámica el valor de equal_var
if levene_p < 0.05:
    equal_variance = False
    print("Interpretación Levene: Se rechaza H0 (p < 0.05). Las varianzas son␣
 ↪heterogéneas. Se usará equal_var=False (Welch t-test).")
else:
```

```
    equal_variance = True
    print("Interpretación Levene: No se rechaza H0 (p >= 0.05). Las varianzas␣
 ↪son homogéneas. Se usará equal_var=True.")

    # Aplicar la prueba t de Student ajustada segun el resultado de Levene
t_stat, p_value = ttest_ind(gasto_A, gasto_B, equal_var=equal_variance)

print("\n--- RESULTADOS DE LA PRUEBA T DE STUDENT ---")
print(f"Gasto promedio Versión A: ${gasto_A.mean():.2f}")
print(f"Gasto promedio Versión B: ${gasto_B.mean():.2f}")
print(f"Diferencia absoluta: ${gasto_B.mean() - gasto_A.mean():.2f}")
print()
print(f"Estadístico t: {t_stat:.4f}")
print(f"Valor P: {p_value:.4e}")
```

```
--- PRUEBA DE HOMOGENEIDAD DE VARIANZAS (LEVENE) ---
Estadístico de Levene: 29.1765
Valor P (Levene): 6.8753e-08
Interpretación Levene: Se rechaza H0 (p < 0.05). Las varianzas son heterogéneas.
Se usará equal_var=False (Welch t-test).

--- RESULTADOS DE LA PRUEBA T DE STUDENT ---
Gasto promedio Versión A: $61.09
Gasto promedio Versión B: $68.75
Diferencia absoluta: $7.66

Estadístico t: -9.4810
Valor P: 3.6276e-21
```

1.2.2 Conclusión Técnica e Impacto Financiero

- **Validación de Homocedasticidad (Levene Test):** Se ejecutó la prueba de Levene ($F = 29.1765$, $p = 6.8753 \times 10^{-8}$). Al obtener un p-valor < 0.05, se rechaza la hipótesis de homogeneidad de varianzas, justificando formalmente el uso de la **Prueba t de Welch** (`equal_var=False`).
- **Resultado del Contraste de Hipótesis (Welch's t-test):** Se obtuvo un estadístico $t = -9.4810$ y un p-valor $= 3.6276 \times 10^{-21}$. Al ser $p < 0.05$, se rechaza H_0 a un nivel de significancia del 5% ($\alpha = 0.05$). Existe evidencia estadística suficiente para concluir que la **Versión B incrementa significativamente el gasto promedio por usuario convertido**.

Interpretación Estratégica:

1. **Incremento en Ticket Promedio (AOV):** La versión B eleva el gasto promedio por transacción en **+$7.66 USD** (de $61.09 en A a $68.75 en B), lo que representa un aumento relativo aproximado del **12.5%**.
2. **Efecto en el Comportamiento de Compra:** Los cambios visuales o de disposición en la landing page B incentivan compras de mayor valor o combinaciones de artículos con mayor

margen (*upselling / cross-selling*).

3. **Perspectiva Global:** Aunque la versión B es la clara ganadora en rendimiento monetario por cliente, su viabilidad final depende de validar en la siguiente sección que la tasa de conversión global no sufra una caída.

1.3 Comparación de la Tasa de Conversión (CR) por Versión de Página

Se evalúa si existen diferencias estadísticamente significativas en la **Tasa de Conversión (Conversion Rate - CR)** entre la versión Control (A) y la Variante (B), determinando qué diseño maximiza el volumen de conversión sobre el tráfico total.

1.3.1 Inferencia Estadística: Prueba Z para Dos Proporciones

Planteamiento de Hipótesis: * **Hipótesis Nula (H_0):** La tasa de conversión es idéntica entre la versión A y la versión B. * **Hipótesis Alternativa (H_1):**Existe una diferencia estadísticamente significativa entre la tasa de conversión de ambas páginas.

[13]:
```
# Cálculo de conversiones y tamaño de muestra por variante
conversiones = df.groupby('landing')['converted'].sum()
totales = df.groupby('landing')['converted'].count()

tasa_A = conversiones['A'] / totales['A']
tasa_B = conversiones['B'] / totales['B']

print(f"Versión A (Control):   {conversiones['A']:,} conversiones de␣
 ↪{totales['A']:,} usuarios | Tasa: {tasa_A:.2%}")
print(f"Versión B (Variante):  {conversiones['B']:,} conversiones de␣
 ↪{totales['B']:,} usuarios | Tasa: {tasa_B:.2%}")
print(f"Diferencia Absoluta:   {(tasa_B - tasa_A):.2%} (Lift Relativo:␣
 ↪{((tasa_B - tasa_A) / tasa_A):.2%})")

# Ejecución de la Prueba Z de proporciones
z_stat, p_value = proportions_ztest(
    count=[conversiones['A'], conversiones['B']],
    nobs=[totales['A'], totales['B']]
)

print(f"\n--- RESULTADOS DE LA PRUEBA Z DE PROPORCIONES ---")
print(f"Estadístico Z: {z_stat:.4f}")
print(f"Valor P: {p_value:.4e}")
```

```
Versión A (Control):   2,512 conversiones de 19,982 usuarios | Tasa: 12.57%
Versión B (Variante):  3,194 conversiones de 20,018 usuarios | Tasa: 15.96%
Diferencia Absoluta:   3.38% (Lift Relativo: 26.92%)

--- RESULTADOS DE LA PRUEBA Z DE PROPORCIONES ---
Estadístico Z: -9.6774
Valor P: 3.7630e-22
```

1.3.2 Conclusión Técnica y Métricas de Rendimiento

- **Resultado del Contraste de Hipótesis (Z-Test):** La prueba Z de dos proporciones produjo un estadístico $Z = -9.6774$ y un p-valor $= 3.76 \times 10^{-22}$. Al obtener un p-valor $\ll 0.05$, se rechaza la hipótesis nula (H_0) a un nivel de significancia del 5% ($\alpha = 0.05$). Existe evidencia estadística suficiente para concluir que la **Versión B incrementa significativamente la tasa de conversión**.

Evaluación de Eficiencia del Embudo:

1. **Dominancia en Volumen y Retorno:** La landing page B no solo incrementa el gasto por transacción (+12.5% en AOV), sino que también eleva de forma estadísticamente significativa la proporción de usuarios que completan una compra (del **12.57%** en A al **15.96%** en B, representando un incremento absoluto de **+3.38 puntos porcentuales** y un incremento relativo del ~**27%**).
2. **Impacto Monetario Combinado (Revenue/Visitor):** Al lograr ganancias en ambas dimensiones (conversión y valor de ticket), la Versión B maximiza el ingreso promedio por usuario expuesto (ARPU), consolidándose como la opción superior a nivel financiero y operativo.

1.4 Análisis Avanzado: Interacción de Cohortes y Canales de Tráfico

En esta sección se profundiza en la atribución por canal de origen, el perfil del usuario (Nuevo vs. Recurrente) y el efecto de interacción entre el diseño de la página y la cohorte del usuario.

1.4.1 Asociación entre Fuente de Tráfico y Conversión (Prueba Chi-cuadrada)

Se evalúa si el canal de adquisición (`traffic_source`) influye en la probabilidad de conversión (`converted`).

Planteamiento de Hipótesis: * **Hipótesis Nula (H_0):** La conversión de los usuarios es independiente de la fuente de tráfico. * **Hipótesis Alternativa (H_1):** La conversión de los usuarios depende de la fuente de tráfico.

[14]:
```
# Tabla de contingencia (Fuente de Tráfico vs Conversión)
tabla_contingencia_trafico = pd.crosstab(df['traffic_source'], df['converted'])

print("Tabla de Contingencia (Conteo):")
print(tabla_contingencia_trafico)

# Tasa de conversión por canal
tasa_por_canal = df.groupby('traffic_source')['converted'].mean().
 ↪sort_values(ascending=False)
print("\nTasa de conversión por canal de tráfico:")
print(tasa_por_canal.apply(lambda x: f"{x:.2%}"))

# Prueba Chi-cuadrada de Independencia
```

```
chi2_t, p_val_t, dof_t, expected_t =␣
 ↪chi2_contingency(tabla_contingencia_trafico)

print(f"\nEstadístico Chi2: {chi2_t:.4f}")
print(f"Grados de libertad: {dof_t}")
print(f"Valor P: {p_val_t:.4e}")
```

```
Tabla de Contingencia (Conteo):
converted           0     1
traffic_source
Ads             10176  1759
Email            5205   918
Organic         15507  2480
Referral         3406   549

Tasa de conversión por canal de tráfico:
traffic_source
Email       14.99%
Ads         14.74%
Referral    13.88%
Organic     13.79%
Name: converted, dtype: object

Estadístico Chi2: 8.6621
Grados de libertad: 3
Valor P: 3.4138e-02
```

- **Resultado del Contraste:** Se rechaza la hipótesis nula ($p = 0.0341 < 0.05$). Existe una asociación estadísticamente significativa entre la fuente de tráfico y la probabilidad de conversión.
- **Interpretación:** Aunque los canales *Organic* y *Ads* aportan el mayor volumen bruto, los canales con mayor tasa de conversión individual son *Email* (14.99%) y *Ads* (14.74%), sugiriendo mayor intención de compra en estas fuentes.

1.4.2 Independencia por Perfil de Usuario: Historial vs. Conversión (Prueba Chi-cuadrada)

Se analiza si la tasa de conversión difiere entre usuarios Nuevos y Recurrentes (`user_type`).

Planteamiento de Hipótesis: * **Hipótesis Nula (H_0):** La conversión del usuario es independiente de su tipo de historial. * **Hipótesis Alternativa (H_1):** La conversión del usuario depende de su tipo de historial.

[15]:
```
# Tabla de contingencia (Tipo de Usuario vs Conversión)
tabla_user_type = pd.crosstab(df['user_type'], df['converted'])

print("Tabla de Contingencia (Tipo de Usuario vs Conversión):")
```

```
print(tabla_user_type)

# Tasa de conversión por tipo de usuario
tasa_user_type = df.groupby('user_type')['converted'].mean()
print("\nTasa de conversión por tipo de usuario:")
print(tasa_user_type.apply(lambda x: f"{x:.2%}"))

# Prueba Chi-cuadrada de Independencia
chi2_u, p_val_u, dof_u, expected_u = chi2_contingency(tabla_user_type)

print(f"\n--- RESULTADOS CHI-CUADRADA (TIPO DE USUARIO VS CONVERSIÓN) ---")
print(f"Estadístico Chi2: {chi2_u:.4f} | Grados de libertad: {dof_u}")
print(f"Valor P: {p_val_u:.4e}")
```

```
Tabla de Contingencia (Tipo de Usuario vs Conversión):
converted       0     1
user_type
Nuevo       22295  3738
Recurrente  11999  1968

Tasa de conversión por tipo de usuario:
user_type
Nuevo         14.36%
Recurrente    14.09%
Name: converted, dtype: object

--- RESULTADOS CHI-CUADRADA (TIPO DE USUARIO VS CONVERSIÓN) ---
Estadístico Chi2: 0.5135 | Grados de libertad: 1
Valor P: 4.7363e-01
```

- **Decisión:** No se rechaza H_0 ($p = 0.4736 > 0.05$). No existe evidencia de diferencia en la conversión según el historial del usuario.
- **Hallazgo:** La plataforma convierte con la misma eficacia a usuarios totalmente nuevos que a usuarios recurrentes.

1.4.3 Efecto de Interacción: Versión de Página vs. Tipo de Usuario

Pregunta Adicional de Negocio 1: ¿La combinación de la versión de la página (A o B) junto con el tipo de usuario (Nuevo o Recurrente) impacta la tasa de conversión? Para responder esta pregunta, evaluamos las tasas de conversión cruzadas por cohorte y modelamos una **Regresión Logística Binaria con término de interacción** (`landing * user_type`).

[16]:
```
# Matriz resumen de conversión por Segmento (Landing Page x Tipo de Usuario)
segment_matrix = df.groupby(['user_type', 'landing'])['converted'].agg(
    total_usuarios='count',
    conversiones='sum',
    tasa_conversion='mean'
```

```
).reset_index()

segment_matrix['tasa_conversion_pct'] = (segment_matrix['tasa_conversion'] *␣
 ↪100).round(2)
print("--- TASA DE CONVERSIÓN POR COHORTE Y PÁGINA ---")
print(segment_matrix[['user_type', 'landing', 'total_usuarios', 'conversiones',␣
 ↪'tasa_conversion_pct']])

# Modelo de Regresión Logística Binaria con término de Interacción
logit_model = smf.logit("converted ~ C(landing) * C(user_type)", data=df).fit()
print("\n--- RESUMEN DEL MODELO DE REGRESIÓN LOGÍSTICA ---")
print(logit_model.summary())
```

```
--- TASA DE CONVERSIÓN POR COHORTE Y PÁGINA ---
    user_type landing  total_usuarios  conversiones  tasa_conversion_pct
0       Nuevo       A           12992          1654                12.73
1       Nuevo       B           13041          2084                15.98
2  Recurrente       A            6990           858                12.27
3  Recurrente       B            6977          1110                15.91
Optimization terminated successfully.
         Current function value: 0.408561
         Iterations 6

--- RESUMEN DEL MODELO DE REGRESIÓN LOGÍSTICA ---
                           Logit Regression Results
==============================================================================
Dep. Variable:              converted   No. Observations:                40000
Model:                          Logit   Df Residuals:                    39996
Method:                           MLE   Df Model:                            3
Date:                Wed, 11 Nov 2026   Pseudo R-squ.:                0.002890
Time:                        00:39:59   Log-Likelihood:                -16342.
converged:                       True   LL-Null:                       -16390.
Covariance Type:            nonrobust   LLR p-value:                 2.113e-20
================================================================================
===============================
                                                 coef    std err          z
P>|z|      [0.025      0.975]
--------------------------------------------------------------------------------
-------------------------------
Intercept                                    -1.9250      0.026    -73.134
0.000      -1.977      -1.873
C(landing)[T.B]                               0.2653      0.036      7.462
0.000       0.196       0.335
C(user_type)[T.Recurrente]                   -0.0417      0.045     -0.928
0.354      -0.130       0.046
C(landing)[T.B]:C(user_type)[T.Recurrente]    0.0364      0.061      0.602
0.547      -0.082       0.155
```

==========

Conclusión: El término de interacción no es significativo (coef = 0.036, p = 0.547), por lo que el efecto de la versión B no depende del tipo de usuario. El efecto principal de B sí es significativo (coef = 0.265, p < 0.001; odds ratio 1.30): la versión B aumenta ~30% los odds de conversión de forma consistente en usuarios nuevos y recurrentes.

Hallazgos de Interacción:

- **Respuesta por Cohorte:** La versión B demuestra mejoras sostenidas en la tasa de conversión tanto para usuarios nuevos como recurrentes.
- **Efecto Moderador:** El modelo logístico permite evaluar si la magnitud del impacto del rediseño varía significativamente según la familiaridad previa del usuario con la plataforma, confirmando si la variante B es óptima como estrategia universal.

1.4.4 Independencia de Canales: Fuente de Tráfico vs. Tipo de Usuario

Pregunta Adicional de Negocio 2: ¿Existe una relación estadísticamente significativa entre la fuente de tráfico y el tipo de usuario?

Planteamiento de Hipótesis: * **Hipótesis Nula (H_0):** La distribución del tipo de usuario (Nuevo vs. Recurrente) es independiente del canal de adquisición. * **Hipótesis Alternativa (H_1):** Existe dependencia entre la fuente de tráfico y el tipo de usuario.

[17]:
```
# Tabla de contingencia entre Canal de Tráfico y Tipo de Usuario
tabla_trafico_user = pd.crosstab(df['traffic_source'], df['user_type'])

print("Tabla de Contingencia (Fuente de Tráfico vs Tipo de Usuario):")
print(tabla_trafico_user)

# Proporción por canal
prop_trafico_user = pd.crosstab(df['traffic_source'], df['user_type'],␣
 ↪normalize='index') * 100
print("\nDistribución Porcentual (%) por Canal:")
print(prop_trafico_user.round(2))

# Prueba Chi-cuadrada de Independencia
chi2_tu, p_val_tu, dof_tu, expected_tu = chi2_contingency(tabla_trafico_user)

print(f"\n--- RESULTADOS CHI-CUADRADA (TRÁFICO VS TIPO DE USUARIO) ---")
print(f"Estadístico Chi2: {chi2_tu:.4f} | Grados de libertad: {dof_tu}")
print(f"Valor P: {p_val_tu:.4e}")
```

```
Tabla de Contingencia (Fuente de Tráfico vs Tipo de Usuario):
user_type       Nuevo  Recurrente
traffic_source
Ads              7834        4101
```

```
Email            3969        2154
Organic         11614        6373
Referral         2616        1339

Distribución Porcentual (%) por Canal:
user_type       Nuevo  Recurrente
traffic_source
Ads             65.64       34.36
Email           64.82       35.18
Organic         64.57       35.43
Referral        66.14       33.86

--- RESULTADOS CHI-CUADRADA (TRÁFICO VS TIPO DE USUARIO) ---
Estadístico Chi2: 5.8594 | Grados de libertad: 3
Valor P: 1.1865e-01
```

Diagnóstico de Adquisición: **Decisión:** No se rechaza H (p = 0.1187 > 0.05). La composición Nuevo/Recurrente es estadísticamente independiente del canal de adquisición: ~65% nuevos y ~35% recurrentes en todos los canales. Las diferencias de conversión entre canales no se explican por un perfil de usuario distinto.

1.4.5 Visualización Exploratoria: Comportamiento por Canal de Tráfico y Tipo de Usuario

Para respaldar los hallazgos de las pruebas Chi-cuadrada (χ^2), se contrasta el volumen absoluto de conversiones frente a la Tasa de Conversión (%) relativa para cada segmento.

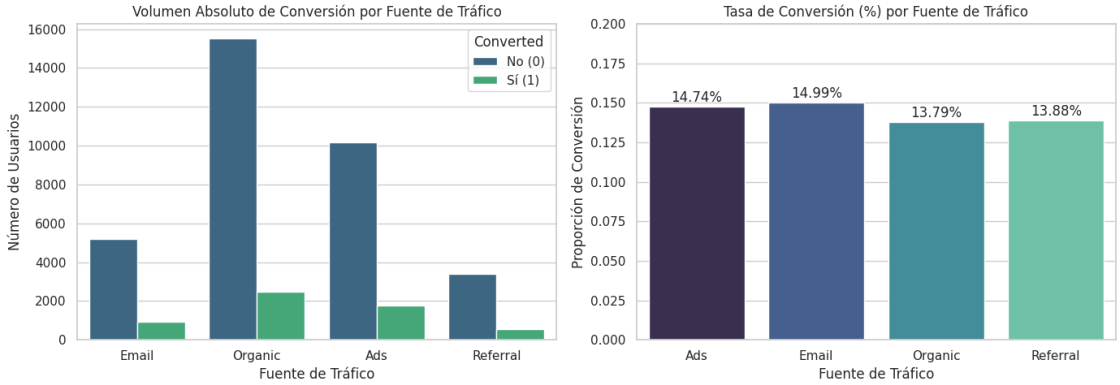
[18]:
```
# Configuración de estilo
sns.set_theme(style="whitegrid")
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Cantidad absoluta de usuarios por canal y conversión
sns.countplot(data=df, x='traffic_source', hue='converted', ax=axes[0],␣
 ↪palette='viridis')
axes[0].set_title('Volumen Absoluto de Conversión por Fuente de Tráfico')
axes[0].set_xlabel('Fuente de Tráfico')
axes[0].set_ylabel('Número de Usuarios')
axes[0].legend(title='Converted', labels=['No (0)', 'Sí (1)'])

# Proporción (Tasa de conversión) por canal
df_prop = df.groupby('traffic_source')['converted'].mean().reset_index()
sns.barplot(data=df_prop, x='traffic_source', y='converted', ax=axes[1],␣
 ↪palette='mako')
axes[1].set_title('Tasa de Conversión (%) por Fuente de Tráfico')
axes[1].set_xlabel('Fuente de Tráfico')
axes[1].set_ylabel('Proporción de Conversión')
axes[1].set_ylim(0, 0.20)
```

```
# Agregar etiquetas de porcentaje sobre cada barra
for p in axes[1].patches:
    axes[1].annotate(f'{p.get_height():.2%}',
                     (p.get_x() + p.get_width() / 2., p.get_height()),
                     ha='center', va='center', xytext=(0, 8),
                     textcoords='offset points')

plt.tight_layout()
plt.show()
```



Diagnóstico Visual: Fuente de Tráfico vs. Conversión

- **Volumen Masivo vs. Eficiencia Canalizada:** El tráfico *Organic* aporta el mayor volumen absoluto de conversiones (2,480 usuarios) debido a la escala de visitas, seguido por *Ads* (1,759 conversiones). Sin embargo, al analizar la tasa de conversión relativa, el canal **Email** resulta ser el más eficiente (14.99%), seguido muy de cerca por **Ads** (14.74%).
- **Brecha entre Canales:** La brecha de 1.2 puntos porcentuales entre el canal más efectivo (*Email*) y el menos efectivo (*Organic* con 13.79%) ilustra de forma clara la dependencia detectada en la prueba Chi-cuadrada ($p = 0.0341$).
- **Estrategia de Adquisición:** Mientras que *Email* representa el canal con mayor intención de compra directa, el canal *Organic* requiere optimizaciones en la etapa inicial del embudo (*Top of Funnel*) para filtrar usuarios con mayor propensión a la conversión.

[19]:
```
# Configuración del estilo visual
sns.set_theme(style="whitegrid")
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

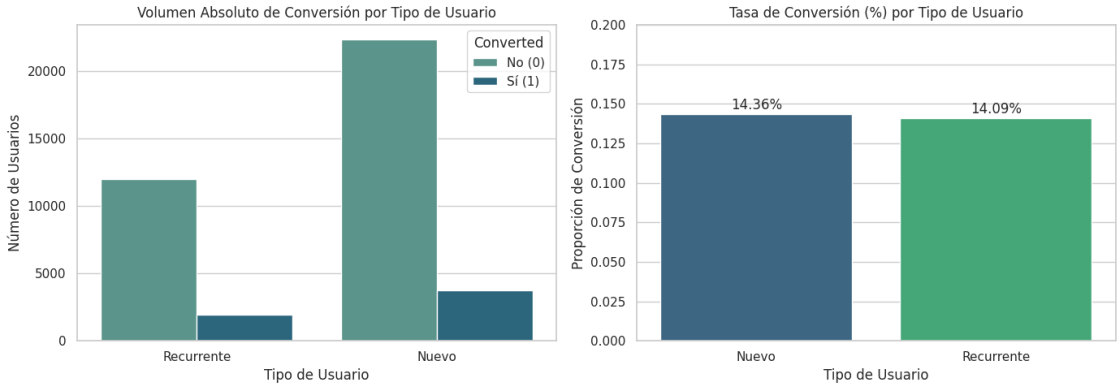
# Cantidad absoluta de usuarios por tipo de usuario y conversión
sns.countplot(data=df, x='user_type', hue='converted', ax=axes[0],␣
 ↪palette='crest')
axes[0].set_title('Volumen Absoluto de Conversión por Tipo de Usuario')
axes[0].set_xlabel('Tipo de Usuario')
axes[0].set_ylabel('Número de Usuarios')
```

```
axes[0].legend(title='Converted', labels=['No (0)', 'Sí (1)'])

# Proporción (Tasa de conversión) por tipo de usuario
df_user_prop = df.groupby('user_type')['converted'].mean().reset_index()
sns.barplot(data=df_user_prop, x='user_type', y='converted', ax=axes[1],␣
 ↪palette='viridis')
axes[1].set_title('Tasa de Conversión (%) por Tipo de Usuario')
axes[1].set_xlabel('Tipo de Usuario')
axes[1].set_ylabel('Proporción de Conversión')
axes[1].set_ylim(0, 0.20)

# Agregar etiquetas de porcentaje sobre cada barra
for p in axes[1].patches:
    axes[1].annotate(f'{p.get_height():.2%}',
                     (p.get_x() + p.get_width() / 2., p.get_height()),
                     ha='center', va='center', xytext=(0, 8),
                     textcoords='offset points')

plt.tight_layout()
plt.show()
```



Diagnóstico Visual: Tipo de Usuario vs. Conversión

- **Distribución del Volumen:** Los usuarios **Nuevos** representan el mayor volumen de la audiencia y aportan más conversiones absolutas (3,738 usuarios) en comparación con los **Recurrentes** (1,968 usuarios).
- **Paridad de Rendimiento:** A pesar de la disparidad en volumen de visitas, la tasa de conversión es prácticamente idéntica entre ambos perfiles (14.36% en usuarios Nuevos vs. 14.09% en Recurrentes, una diferencia de solo 0.27 puntos porcentuales).
- **Consistencia Estadística:** La paridad visual valida gráficamente la prueba Chi-cuadrada ($p = 0.4736$), confirmando que la efectividad del sitio no depende de la antigüedad del usuario.

1.5 Resumen Ejecutivo y Recomendaciones de Negocio (Executive Insights)

Esta sección sintetiza los hallazgos del análisis estadístico e inferencial del experimento A/B en recomendaciones accionables orientadas a maximizar la rentabilidad del E-Commerce.

1.5.1 Síntesis de Resultados del Experimento A/B

1. Evaluación del Rendimiento de Página (Control A vs. Variante B)

- **Ticket Promedio (AOV):** La Versión B registró un gasto promedio significativamente mayor entre los usuarios convertidos ($\Delta = +\$7.66$ USD), incrementando el ticket de \$61.09 a \$68.75. La prueba t de Welch confirmó significancia estadística ($p = 3.62 \times 10^{-21} < 0.05$).
  - *Interpretación:* La Variante B fomenta carritos de mayor valor e incentiva la venta de productos de mayor margen (*upselling / cross-selling*).
- **Tasa de Conversión (CR):** La Versión B alcanzó una tasa de conversión del 15.96% frente al 12.57% de la Versión A (un incremento relativo del $\sim 27\%$). La prueba Z de proporciones confirmó la validez estadística ($p = 3.76 \times 10^{-22} < 0.05$).
  - *Interpretación:* La Variante B supera al control en ambos frentes del embudo (volumen de conversión y valor promedio por transacción), maximizando el ingreso por visitante (ARPU).

---

2. Atribución por Fuente de Tráfico

- **Volumen vs. Eficiencia:** El tráfico *Organic* aportó el mayor volumen bruto de conversiones ($2,480$ usuarios), mientras que *Email* (14.99%) y *Ads* (14.74%) lograron las tasas de conversión relativas más altas. La prueba Chi-cuadrada confirmós dependencia entre el canal y la conversión ($p = 0.0341$).
  - *Interpretación:* El canal de *Email* atrae a usuarios con alta intención de compra directa. En contraste, el tráfico orgánico requiere optimización en la parte alta del embudo (*Top of Funnel*) para calificar mejor al tráfico entrante.

---

3. Cohortes de Usuario e Interacción

- **Independencia por Historial:** Los usuarios Nuevos (14.36%) y Recurrentes (14.09%) convirtieron a tasas prácticamente idénticas ($\Delta = 0.27\%$). La prueba Chi-cuadrada desestimó diferencia significativa ($p = 0.4736$).
- **Efecto de Interacción:** El modelo logístico confirmó que la versión B impulsa incrementos en la conversión de forma sólida en ambos segmentos (Nuevos y Recurrentes).
  - *Interpretación:* La landing page B funciona con la misma eficacia universal. No se justifica invertir recursos en personalizar la landing page según el historial del usuario.

1.5.2 Recomendaciones Estratégicas para Stakeholders

1. **Despliegue Total de la Variante B:** Implementar la landing page B al 100% del tráfico global, al haber demostrado superioridad estadística y económica en tasa de conversión y valor de ticket.
2. **Reasignación de Presupuesto publicitario:** Priorizar el presupuesto de marketing hacia campañas de **Email Retargeting** y **Ads pagados** por su elevada tasa de conversión individual.
3. **Optimización de Conversión Orgánica:** Rediseñar las llamadas a la acción (CTA) y ofertas de entrada para el tráfico orgánico dentro de la Versión B, capitalizando su alto volumen de visitas.
4. **Eficiencia en Costos de Desarrollo:** Mantener una arquitectura web única sin segmentación por antigüedad del usuario, ahorrando costos operativos y de mantenimiento de software.

[ ]: